

支持向量机入门指北

Apple Zhang

Shenzhen University

April 8, 2023



目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM
- 5 非线性SVM
- 6 其他...



目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM
- 5 非线性SVM
- 6 其他...



符号定义

- 第 i 个训练样本: $\mathbf{x}_i = [x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(d)}]^T \in \mathbb{R}^d$.
- 第 i 个训练样本的标签: $y_i \in \{-1, 1\}$.
- 训练样本矩阵: $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n] \in \mathbb{R}^{d \times n}$.
- 训练样本标签向量: $\mathbf{y} = [y_1, y_2, \dots, y_n] \in \{-1, 1\}^n$.
- 超平面的法向量: $\mathbf{w} \in \mathbb{R}^d$.
- 超平面的偏移: $b \in \mathbb{R}$
- L_2 范数:

$$\|x\|_2 = \sqrt{\sum_{i=1}^d x_i^2} = \sqrt{\mathbf{x}^T \mathbf{x}}.$$

- 损失函数: $\mathcal{L}(\cdot)$.
- 拉格朗日函数: $L(\cdot)$.
- 求梯度/求导: ∇f .



什么是超平面？

- 在 \mathbb{R}^2 空间中, 一条**直线**可表示为点集

$$\left\{ (x^{(1)}, x^{(2)}) \mid w_1 x^{(1)} + w_2 x^{(2)} + b = 0 \right\}.$$

- 在 \mathbb{R}^3 空间中, 一个**平面**可表示为点集

$$\left\{ (x^{(1)}, x^{(2)}, x^{(3)}) \mid w_1 x^{(1)} + w_2 x^{(2)} + w_3 x^{(3)} + b = 0 \right\}.$$

- 在 \mathbb{R}^d 空间中, 一个**超平面**可表示为点集

$$\{\mathbf{x} \mid \mathbf{w}^T \mathbf{x} + b = 0\}$$

即:

$$\left\{ (x^{(1)}, x^{(2)}, \dots, x^{(d)}) \mid w_1 x^{(1)} + w_2 x^{(2)} + \dots + w_d x^{(d)} + b = 0 \right\}$$



深圳大学
SHENZHEN UNIVERSITY

数据点到超平面的距离

- 在 \mathbb{R}^2 空间中, 数据点 $\mathbf{x}_i = [x_i^{(1)}, x_i^{(2)}]^T$ 到一条直线的距离:

$$\frac{|w_1 x_i^{(1)} + w_2 x_i^{(2)} + b|}{\sqrt{w_1^2 + w_2^2}}.$$

- 在 \mathbb{R}^3 空间中, 数据点 $\mathbf{x}_i = [x_i^{(1)}, x_i^{(2)}, x_i^{(3)}]^T$ 到一个平面的距离:

$$\frac{|w_1 x_i^{(1)} + w_2 x_i^{(2)} + w_3 x_i^{(3)} + b|}{\sqrt{w_1^2 + w_2^2 + w_3^2}}.$$

- 在 \mathbb{R}^d 空间中, 数据点 $\mathbf{x}_i = [x_i^{(1)}, x_i^{(2)}, \dots, x_i^{(d)}]^T$ 到超平面的距离:


$$\begin{aligned} & \frac{|w_1 x_i^{(1)} + w_2 x_i^{(2)} + \dots + w_d x_i^{(d)} + b|}{\sqrt{w_1^2 + w_2^2 + \dots + w_d^2}} \\ &= \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|_2}. \end{aligned}$$



分类问题——线性可分

问题:

对于一个二分类问题，假设数据是线性可分的 (linear separable)，如何找到一个超平面把两类数据分开？




关键词:

- 超平面: $\mathbf{w}^T \mathbf{x} + b = 0$.
- 预测函数:
 $h(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \mathbf{x} + b)$.
- 线性可分: 存在至少一个超平面, 使得
 $\forall i, y_i = h(\mathbf{x}_i)$.




深圳大学
SHENZHEN UNIVERSITY

如何对这个数据分类



如何对这个数据分类




目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM
- 5 非线性SVM
- 6 其他...



最大间隔分类器: 支持向量机

SVM 寻找最大化两个类间的间隔的超平面[1].




SVM 的优化目标

定义 (间隔)

样本集 $\{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n\}$ 到超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的间隔，等于离超平面最近的那个点到超平面的距离：


$$\rho = \min_{i=1,2,\dots,n} \frac{|\mathbf{w}^T \mathbf{x}_i + b|}{\|\mathbf{w}\|_2} = \min_{i=1,2,\dots,n} \frac{y_i(\mathbf{w}^T \mathbf{x}_i + b)}{\|\mathbf{w}\|_2} \quad (1)$$



SVM 的优化目标

总间隔等于正类样本和负类样本到超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的间隔之和:

$$\rho = \rho_+ + \rho_- . \quad (2)$$



SVM 的优化目标

- 假设 $\rho_+ = \rho_-$ ，即分类超平面处于中间；（为什么？）
- 则可以设超平面（虚线）为 $\mathbf{w}^T \mathbf{x} + b = 1$ 和 $\mathbf{w}^T \mathbf{x} + b = -1$ ；（为什么？）
- 所以超平面有以下约束；（为什么？）

$$\begin{cases} \mathbf{w}^T \mathbf{x}_i + b \geq 1, & \text{if } y_i = 1, \\ \mathbf{w}^T \mathbf{x}_i + b \leq -1, & \text{if } y_i = -1. \end{cases} \Leftrightarrow y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1. \quad (3)$$

- 因此，两类样本到超平面 $\mathbf{w}^T \mathbf{x} + b = 0$ 的间隔均为：（为什么？）

$$\rho_+ = \rho_- = \frac{1}{\|\mathbf{w}\|_2}. \quad (4)$$



SVM 的优化问题

要最大化两个类之间的间隔, 则有

$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2}, \quad \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1. \quad (5)$$

同时, 由于

$$\max_{\mathbf{w}, b} \frac{2}{\|\mathbf{w}\|_2} \Leftrightarrow \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2.$$

所以可以将最大化间隔的问题转化为如下的优化问题

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2, \quad \text{s.t. } y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1.$$



带不等式约束的优化问题

定义以下带不等式约束的优化问题:

$$\min_{\mathbf{u}} f_0(\mathbf{u}), \quad \text{s.t. } f_i(\mathbf{u}) \leq 0, \quad i = 1, 2, \dots, n. \quad (6)$$

定义 (6) 对应的拉格朗日函数为

$$L(\mathbf{u}, \boldsymbol{\alpha}) = f_0(\mathbf{u}) + \sum_{i=1}^n \alpha_i f_i(\mathbf{u}). \quad (7)$$

在 SVM 的问题中, $\mathbf{u} = (\mathbf{w}, b)$, 以及

$$f_0(\mathbf{u}) = \frac{1}{2} \|\mathbf{w}\|^2, \quad f_i(\mathbf{u}) = 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b). \quad (8)$$



用对偶问题求解 SVM

SVM 的拉格朗日函数为

$$L(\mathbf{w}, b, \boldsymbol{\alpha}) = \frac{1}{2} \|\mathbf{w}\|_2^2 + \sum_{i=1}^n \alpha_i [1 - y_i(\mathbf{w}^T \mathbf{x}_i + b)]. \quad (9)$$

定理

求解 SVM 原问题等价于求解如下的对偶问题:

$$\max_{\boldsymbol{\alpha} \geq 0} \min_{\mathbf{w}, b} L(\mathbf{w}, b, \boldsymbol{\alpha}). \quad (10)$$

$$= \max_{\boldsymbol{\alpha} \geq 0} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0. \quad (11)$$



用对偶问题求解 SVM

$$\max_{\alpha \geq 0} \min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + \sum_{i=1}^n \alpha_i [1 - y_i (\mathbf{w}^T \mathbf{x}_i + b)].$$

首先对于 \mathbf{w}, b 最小化 $L(\mathbf{w}, b, \alpha)$:

$$\nabla_{\mathbf{w}} L = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i,$$

$$\nabla_b L = 0 \Rightarrow 0 = \sum_{i=1}^n \alpha_i y_i.$$

将以上条件代入，得到如下的二次规划问题:

$$\max_{\alpha \geq 0} \sum_{i=1}^n \alpha_i - \frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j, \quad \text{s.t.} \quad \sum_{i=1}^n \alpha_i y_i = 0.$$



用对偶问题求解 SVM

化为标准二次规划的矩阵形式:

$$\min_{\alpha} \frac{1}{2} \alpha^T \mathbf{Q} \alpha - \mathbf{1}^T \alpha, \quad \text{s.t. } \alpha_i \geq 0, \mathbf{y}^T \alpha = 0.$$

这里 $\mathbf{1}$ 是全1的列向量, $\mathbf{Q} \in \mathbb{R}^{n \times n}$ 的每一个元素是

$$Q_{ij} = y_i y_j \mathbf{x}_i^T \mathbf{x}_j.$$

实际实现中可以调用 Matlab 的函数: `quadprog`¹, 对于Python, 可以使用 `cvxopt` 中的 `solvers.qp`² 函数。
最后, 我们可以把预测函数写为

$$h(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \mathbf{x} + b) = \text{sgn} \left(\sum_{i=1}^n \alpha_i y_i \mathbf{x}_i^T \mathbf{x} + b \right).$$

¹需要 Matlab Optimization toolbox

²需要 numpy-mkl



小贴士

$$\min_{\alpha} \frac{1}{2} \alpha^T \mathbf{Q} \alpha - \mathbf{1}^T \alpha, \quad \text{s.t. } \alpha_i \geq 0, \mathbf{y}^T \alpha = 0.$$

- 上式解出的 α 是稀疏的. 如果 $\alpha_i > 0$, 则其对应的训练样本 \mathbf{x}_i 称为支持向量(Support Vector, SV).
- b 可以用下面的公式算出:

$$b = \frac{1}{\|\alpha\|_0} \sum_{\alpha_i > 0} \left(\frac{1}{y_i} - \sum_{j=1}^n \alpha_j y_j \mathbf{x}_j^T \mathbf{x}_i \right).$$

其中 $\|\cdot\|_0$ 表示 L_0 范数算子, 返回向量非零元素个数.



小贴士

$$\min_{\alpha} \frac{1}{2} \alpha^T Q \alpha - \mathbf{1}^T \alpha, \quad \text{s.t. } \alpha_i \geq 0, \mathbf{y}^T \alpha = 0.$$

Matlab函数: `x = quadprog(H, f, A, b, Aeq, Beq, lb, ub, x0);`

$$\min_{\mathbf{x}} \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} + \mathbf{f}^T \mathbf{x}, \quad \text{s.t.} \quad \begin{cases} \mathbf{A} \cdot \mathbf{x} \leq \mathbf{b} \\ \mathbf{A} \text{eq} \cdot \mathbf{x} = \mathbf{b} \text{eq} \\ lb \leq \mathbf{x} \leq ub \end{cases}$$

因此对偶问题可以按以下方式求解:

$$\text{alpha} = \text{quadprog}(\mathbf{Q}, -\mathbf{1}, [], [], \mathbf{y}^T, 0, \mathbf{0}, [], \mathbf{x}_0)$$

注意: 需要安装Matlab Optimization toolbox.



目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理**
- 4 软间隔SVM
- 5 非线性SVM
- 6 其他...



初探对偶原理

对于下面的不等式优化问题以及拉格朗日函数

$$\min_{\mathbf{u}} f_0(\mathbf{u}), \quad \text{s.t. } f_i(\mathbf{u}) \leq 0, \quad i = 1, 2, \dots, n, \quad (12)$$

$$L(\mathbf{u}, \boldsymbol{\alpha}) = f_0(\mathbf{u}) + \sum_{i=1}^n \alpha_i f_i(\mathbf{u}). \quad (13)$$

我们有以下结论

定理

设原问题(12)的最优值为 p^* , 则

$$p^* = \min_{\mathbf{u}} \max_{\boldsymbol{\alpha}} L(\mathbf{u}, \boldsymbol{\alpha}), \quad \text{s.t. } \alpha_i \geq 0. \quad (14)$$



初探对偶原理

证明: 定义 $\theta(\mathbf{u})$ 为

$$\begin{aligned}\theta(\mathbf{u}) &= \max_{\alpha \geq 0} L(\mathbf{u}, \alpha) \\ &= \max_{\alpha \geq 0} f_0(\mathbf{u}) + \sum_{i=1}^n \alpha_i f_i(\mathbf{u}).\end{aligned}\tag{15}$$

可以看到, 拉格朗日函数是关于 α_i 的线性函数, 于是分以下两种情况讨论:

- $\forall i \in \{1, 2, \dots, n\}, f_i(\mathbf{u}) \leq 0 \Rightarrow \theta(\mathbf{u}) = f_0(\mathbf{u}).$
- $\exists i \in \{1, 2, \dots, n\}, f_i(\mathbf{u}) > 0 \Rightarrow \theta(\mathbf{u}) = +\infty.$

所以

$$\theta(\mathbf{u}) = \begin{cases} f_0(\mathbf{u}), & \forall i \in \{1, 2, \dots, n\}, f_i(\mathbf{u}) \leq 0, \\ +\infty, & \text{otherwise.} \end{cases}$$

初探对偶原理

$$\theta(\mathbf{u}) = \begin{cases} f_0(\mathbf{u}), & \forall i \in \{1, 2, \dots, n\}, f_i(\mathbf{u}) \leq 0, \\ +\infty, & \text{otherwise.} \end{cases}$$

考虑 $\theta(\mathbf{u})$ 的最小值, 由于必定有 $f_0(\mathbf{u}) < +\infty$, 所以

$$\begin{aligned} \min_{\mathbf{u}} \theta(\mathbf{u}) &= \min_{\mathbf{u}} f_0(\mathbf{u}), \quad \text{s.t. } f_i(\mathbf{u}) \leq 0, i = 1, 2, \dots, n \\ &= p^*. \end{aligned} \tag{16}$$

也就是说,

$$\min_{\mathbf{u}} \max_{\alpha \geq 0} L(\mathbf{u}, \alpha) = \min_{\mathbf{u}} \theta(\mathbf{u}) = p^*. \tag{17}$$



初探对偶原理

我们假设对偶问题的最优值为

$$d^* = \max_{\alpha \geq 0} \min_{\mathbf{u}} L(\mathbf{u}, \alpha) \quad (18)$$

问题：下面的等式一定成立吗？

$$p^* = \underbrace{\min_{\mathbf{u}} \max_{\alpha \geq 0} L(\mathbf{u}, \alpha)}_{\text{原问题}} = \underbrace{\max_{\alpha \geq 0} \min_{\mathbf{u}} L(\mathbf{u}, \alpha)}_{\text{对偶问题}} = d^* \quad (19)$$

下面这个不等式呢？

$$p^* = \underbrace{\min_{\mathbf{u}} \max_{\alpha \geq 0} L(\mathbf{u}, \alpha)}_{\text{原问题}} \geq \underbrace{\max_{\alpha \geq 0} \min_{\mathbf{u}} L(\mathbf{u}, \alpha)}_{\text{对偶问题}} = d^* \quad (20)$$



初探对偶原理

- $p^* \geq d^*$ 称为弱对偶性，这个性质对任何优化问题**总是成立**。
- $p^* = d^*$ 称为强对偶性，只有一部分优化问题满足这个性质。

Slater 条件是原问题满足强对偶性的充分条件：

定理 (*Slater 条件)

设定义在 \mathcal{D} 上的函数 $f_i(\cdot), i = 0, 1, \dots, n$ 均为凸函数，对于优化问题

$$\min_{\mathbf{u}} f_0(\mathbf{u}), \quad \text{s.t. } f_i(\mathbf{u}) \leq 0.$$

如果存在点 $\tilde{\mathbf{u}} \in \text{relint} \mathcal{D}$ （即定义域 \mathcal{D} 的相对内点），使得 $f_i(\tilde{\mathbf{u}}) < 0$ ，则强对偶性成立。




目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM**
- 5 非线性SVM
- 6 其他...



如果数据分布不理想...

硬间隔SVM 的要求是数据严格线性可分，但一般这个条件不成立。
我们更多使用的是**软间隔SVM**。



软间隔SVM

软间隔 SVM 的优化问题:

$$\begin{aligned} \min_{\mathbf{w}, b, \xi} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + c \sum_{i=1}^n \xi_i, \\ \text{s.t.} \quad & y_i(\mathbf{w}^T \mathbf{x}_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \end{aligned}$$

其中 c 是惩罚参数. 上述问题的拉格朗日函数:

$$L(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|_2^2 + c \sum_{i=1}^n \xi_i + \sum_{i=1}^n [\alpha_i (1 - \xi_i - y_i(\mathbf{w}^T \mathbf{x}_i + b))] - \sum_{i=1}^n \beta_i \xi_i. \quad (21)$$

对偶问题:

$$\max_{\alpha} \mathbf{1}^T \alpha - \frac{1}{2} \alpha^T \mathbf{Q} \alpha, \quad \text{s.t. } 0 \leq \alpha_i \leq c, \quad \mathbf{y}^T \alpha = 0.$$



软间隔SVM

软间隔 SVM 等价于以下的结构化损失最小化模型

$$\min_{\mathbf{w}, b} \underbrace{\frac{1}{2} \|\mathbf{w}\|_2^2}_{L_2 \text{正则}} + c \sum_{i=1}^n \underbrace{\max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))}_{L_1 \text{铰链损失}}. \quad (22)$$

从这个优化模型出发，可以得出很多 SVM 的变种模型：

$$\min_{\mathbf{w}, b} \frac{1}{2} \|\mathbf{w}\|_2^2 + c \sum_{i=1}^n \max(0, 1 - y_i(\mathbf{w}^T \mathbf{x}_i + b))^2, \quad (23)$$

$$\min_{\mathbf{w}} \frac{1}{2} \|\mathbf{w}\|_2^2 + c \sum_{i=1}^n \max(0, 1 - y_i \mathbf{w}^T \mathbf{x}_i). \quad (24)$$



目录



- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM
- 5 非线性SVM**
- 6 其他...



非线性分类: 核 SVM





前面使用的都是线性模型. 如果数据是非线性分布的, 则效果会较差.

核 SVM: 通过核方法完成非线性分类.



深圳大学
SHENZHEN UNIVERSITY

非线性分类: 核 SVM



深圳大学
SHENZHEN UNIVERSITY

核技巧

定义 (正定对称核)

定义函数 $\mathcal{K} : \mathbb{R}^d \times \mathbb{R}^d \mapsto \mathbb{R}$. 若对任意在 \mathbb{R}^d 上的数据集: $\{\mathbf{x}_1, \dots, \mathbf{x}_n\}$, 矩阵 $\mathbf{K} \in \mathbb{R}^{n \times n}$ 满足 $K_{ij} = \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j)$, 且 \mathcal{K} 是对称正定的, 则称 \mathcal{K} 是正定对称核.

对任意正定对称核, 存在唯一的特征空间 \mathcal{H} 以及映射 $\phi : \mathbb{R}^d \mapsto \mathcal{H}$, 使得

$$\mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = \langle \phi(\mathbf{x}_i), \phi(\mathbf{x}_j) \rangle = \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j). \quad (25)$$

高斯核函数 (或 RBF 核函数) 是最常见的核函数之一:

$$\mathcal{K}(\mathbf{x}_i, \mathbf{x}_j) = \exp \left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|_2^2}{t} \right), \quad t > 0. \quad (26)$$

核函数可以隐式确定一个非线性映射 $\phi(\cdot)$, 于是不需要知道 $\phi(\cdot)$ 的具体表达式就可以计算非线性映射后的内积.



核 SVM

对于经过非线性映射后的数据 $\phi(\mathbf{x})$, 运用软间隔 SVM, 求以下超平面:

$$\mathbf{w}^T \phi(\mathbf{x}) + b = 0. \quad (27)$$

对应的 SVM 优化问题是:

$$\begin{aligned} \min_{\mathbf{w}, b} \quad & \frac{1}{2} \|\mathbf{w}\|_{\mathcal{H}}^2 + c \sum_{i=1}^n \xi_i, \\ \text{s.t.} \quad & y_i (\mathbf{w}^T \phi(\mathbf{x}_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0. \end{aligned} \quad (28)$$

实际上, 只是将软间隔 SVM 中的 \mathbf{x}_i 都替换成了 $\phi(\mathbf{x}_i)$.



核技巧

拉格朗日函数:

$$L(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|_{\mathcal{H}}^2 + c \sum_{i=1}^n \xi_i + \sum_{i=1}^n [\alpha_i (1 - \xi_i - y_i(\mathbf{w}^T \phi(\mathbf{x}_i) + b))] - \sum_{i=1}^n \beta_i \xi_i. \quad (29)$$

$$\nabla_{\mathbf{w}} L = 0 \Rightarrow \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \phi(\mathbf{x}_i),$$

$$\nabla_b L = 0 \Rightarrow \sum_{i=1}^n \alpha_i y_i = 0,$$

$$\nabla_{\xi_i} L = 0 \Rightarrow c - \alpha_i - \beta_i = 0.$$



核方法

对偶问题:

$$\begin{aligned} \max_{\alpha} \quad & \mathbf{1}^T \alpha - \frac{1}{2} \alpha^T \mathbf{Q}^\varphi \alpha, \\ \text{s.t.} \quad & 0 \leq \alpha_i \leq c, \mathbf{y}^T \alpha = 0. \end{aligned}$$

其中 $\mathbf{Q}^\varphi \in \mathbb{R}^{n \times n}$ 定义为:

$$Q_{ij}^\varphi = y_i y_j \phi(\mathbf{x}_i)^T \phi(\mathbf{x}_j) = y_i y_j \mathcal{K}(\mathbf{x}_i, \mathbf{x}_j).$$

注意: 在核 SVM 中, 测试样本 \mathbf{x} 的标签需要通过以下方式计算:

$$h(\mathbf{x}) = \text{sgn}(\mathbf{w}^T \phi(\mathbf{x}) + b) = \text{sgn} \left(\sum_{i=1}^n \alpha_i y_i \mathcal{K}(\mathbf{x}_i, \mathbf{x}) + b \right).$$

核 SVM 的预测必须依赖训练集.



目录

- 1 背景知识
- 2 硬间隔SVM
- 3 *对偶原理
- 4 软间隔SVM
- 5 非线性SVM
- 6 其他...



更多有关SVM...

高效的SVM解决方案(C++实现): **LIBSVM**, **LIBLINEAR**[2, 3].

- 已有C++, Java, MATLAB, Python接口.
- 贼快.

其他SVM的变种:

- (1999 NPL) Least Square Support Vector Machine (LSSVM) [4].
- (2001 JMLR) Crammer-Singer Support Vector Machine (CSSVM) [5].
- (2006 JMLR) Laplacian Support Vector Machine (Lap-SVM) [6].
- (2007 PAMI) Twin Support Vector Machine (TWSVM) [7].
- (2019 NN) Capped-norm Twin Support Vector Machine (CTWSVM)[8].
- (2022 TCYB) Robust Manifold Twin Bounded SVM [9].
- (2023 TCYB) Maximal Margin SVM [10]



结束

谢谢!

<https://github.com/Apple-Zhang/SVM-Intro>



深圳大学
SHENZHEN UNIVERSITY

参考文献

- [1] C. Cortes and V. Vapnik, "Support-vector networks," *Machine learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [2] C.-C. Chang and C.-J. Lin, "Libsvm: a library for support vector machines," *ACM transactions on intelligent systems and technology (TIST)*, vol. 2, no. 3, pp. 1–27, 2011.
- [3] R.-E. Fan, K.-W. Chang, C.-J. Hsieh, X.-R. Wang, and C.-J. Lin, "Liblinear: A library for large linear classification," *the Journal of machine Learning research*, vol. 9, pp. 1871–1874, 2008.
- [4] J. A. Suykens and J. Vandewalle, "Least squares support vector machine classifiers," *Neural processing letters*, vol. 9, no. 3, pp. 293–300, 1999.
- [5] K. Crammer and Y. Singer, "On the algorithmic implementation of multiclass kernel-based vector machines," *Journal of machine learning research*, vol. 2, no. Dec, pp. 265–292, 2001.
- [6] M. Belkin, P. Niyogi, and V. Sindhwani, "Manifold regularization: A geometric framework for learning from labeled and unlabeled examples," *Journal of machine learning research*, vol. 7, no. 11, 2006.
- [7] R. Khemchandani, S. Chandra, *et al.*, "Twin support vector machines for pattern classification," *IEEE Transactions on pattern analysis and machine intelligence*, vol. 29, no. 5, pp. 905–910, 2007.
- [8] C. Wang, Q. Ye, P. Luo, N. Ye, and L. Fu, "Robust capped l1-norm twin support vector machine," *Neural Networks*, vol. 114, pp. 47–59, 2019.
- [9] J. Zhang, Z. Lai, H. Kong, and L. Shen, "Robust twin bounded support vector classifier with manifold regularization," *IEEE Transactions on Cybernetics*, pp. 1–16, 2022.
- [10] Z. Lai, X. Chen, J. Zhang, H. Kong, and J. Wen, "Maximal margin support vector machine for feature representation and classification," *IEEE Transactions on Cybernetics*, 2023.

